

Фичестор Городских сервисов Яндекса

Павел Попов

Руководитель группы разработки
передовых технологий, Яндекс Go

infra.conf

1. Что такое Feature Store?

2. Рождение Avalon

3. UGcdb Framework

4. Proxy и Data Processor

5. Технические характеристики

Что такое **Feature Store?**

Feature Store — витрина признаков.
Основными её задачами являются:

- Хранение признаков
- Каталогизация признаков

AVALONINT-57

- Сегмент доверенных пользователей Маркета
- Хотим настроить поставку нового свойства доверенного пользователя на Маркете в Авалон, которое затем сможем использовать в новом маркетном перке.
- Антифрод раз в сутки размечает все паспортные аккаунты на предмет доверенности на Маркете, под капотом используя экосистемные фичи и разметку нарушителей сервиса. Хотим поставлять булев признак на пользователе – доверенный он или нет.
- **По объёмам:** чуть более 80% аккаунтов (1,65 млрд) признаём доверенными. В качестве варианта можем поставлять обратное свойство недоверенности на 403 млн пользователей.

AVALONINT-57

- Дифф по доверенным:
не более 2 млн записей в сутки
- Предполагаемый объём
данных (GiB | ключей): **1,65 млрд**
- Для какого идентификатора
добавляется признак?: **passport_uid**
- Это экспериментальный признак?: **Нет**
- Сколько дней нужно хранить данные
при отсутствии обновлений?: **30**
- Каков источник данных?: **YT**
- Потребуется ли первоначальная
наливка историческими данными?: **Нет**

1. Что такое Feature Store?

2. Рождение Avalon

3. UGCDB Framework

4. Proxy и Data Processor

5. Технические характеристики

Принесли таблицу

Metadata ^

Id	30c6f-86e261-3fe0191-688884f2	⌚	Rows	1 766 842 971	Table type	static	Sorted	false
Owner	robot-taxi-prd-41663		Chunks	939	Optimize for	Lookup		
Account	taxi-efficiency		Uncompressed size	73.63 GiB	Compression ratio	0.20506		
Creation time	29 May 2025 22:42:50		Compressed size	15.10 GiB	Compression codec	Iz4		
Modification time	29 May 2025 22:54:11		Primary medium	Default	Replication factor	3		
Access time	29 May 2025 22:54:12		Total disk space	45.31 GiB				
			Data weight	57.18 GiB				

« < > » # No offset Columns 2/2 ⚙ YQL Kit Jupyter DataLens Download Upload ...

#	“Data”	“Key”
0	{ “name”: “trusted_user” }	“99953137”
1	{ “name”: “trusted_user” }	“999531370”
2	{ “name”: “trusted_user” }	“999531371”

Сервис тегирования аудитории

Праородитель Avalon,
рождённый в такси:

- Построен на базе PostgreSQL
- Хранит бинарные признаки
- Удобный способ разметки данными для аналитиков
- Помог запустить не один десяток проектов в Екоме и Райдтехе

Плюсы

- Низкий Time To Market.
- Простой и привычный для аналитиков интерфейс.
- Исторически «доступен» практически в каждом уголке Екома и Райдтеха — для проверки практически любой гипотезы не требуется разработка.

Минусы

- PostgreSQL — ограниченные размеры, необходимо ручное шардирование, дешевле было развернуть новую инсталляцию, чтобы масштабировать. Итог — 5 инсталляций.
- Сложно отследить использование признака — сложно поддерживать актуальность признака и искать реальных потребителей.
- Абьюз сервиса: «бесконечные» разметки, «хардкод» в названиях признаков.

Требования к Avalon

- Единая точка входа для потребителей
- «Бесконечное» количество признаков
- Признаки могут быть произвольными данными
- Признаки должны поставляться из Runtime- и Offline-контуров
- Удобный реестр признаков
- Лёгкий и быстрый способ разметки аудитории для проверки гипотез или проведения экспериментов
- Возможность отслеживать потребление признаков

Как получать данные

```
taxi-tvm-curl --env testing avalon-proxy -v avalon-proxy.tst.yandex.net/v1/fetch-features -X POST -H "Content-Type: application/json" -d '{"id": "1000025037", "features": ["/market-general/{}/features/trusted_user"]}'
```

```
{  
    "id": "1000025037",  
    "features": {  
        "/market-general/{}/features/trusted_user": {  
            "data": {  
                "@type":  
                    "type.googleapis.com/NUgc.NSchema.NAvalon.TGeneralFeature",  
                "name": "trusted_user"  
            }  
        }  
    }  
}
```

Домен одной ручки



1. Что такое Feature Store?

2. Рождение Avalon

3. UGCDB Framework

4. Proxy и Data Processor

5. Технические характеристики

Философия фреймворка

- KV хранилище данных
- если запись должна быть в единственном экземпляре — то это колонка по этому пути
- если данных с типом несколько — это таблица
- внутри таблицы могут быть таблицы

Достоинства UGCDB

Хранилище

- YDB
- Иерархическое Key Value
- Удобное шардирование

Схема данных

- Описывается Protobuf
- Логическая схема данных
- Одна таблица

API

- Обобщённое API генерируется по схеме данных

CDC

- Внешняя реализация
- Возможность гибкой настройки

Физическая схема таблицы

```
Uint32 ShardId;    // Логический номер шарда
String Key;        // Ключ данных
String ValueProto; // Сообщение, сериализованное в бинарном виде
Json ValueJson;   // Сообщение, сериализованное в JSON-формате
Timestamp CreateTime; // Время создания записи
Timestamp UpdateTime; // Время последнего обновления записи
Timestamp ExpireAt; // Время, после которого запись автоматически удаляется
Uint64 __tablet;   // Системное, номер таблетки
Uint64 __updateEpoch; // Системное, счётчик (сбрасывается на изменениях таблетки)
Uint64 __updateNo;  // Системное, счётчик (общий для всех записей)
```

Логическая схема данных

```
message TRoot {  
    repeated TGeneralFeatureStorage MarketGeneral = 1;  
  
    option (schema) {  
        Table: {  
            Name: "market-general"  
            Field: "MarketGeneral"  
            Key: "Name"  
        }  
    }  
};
```

Логическая схема данных

```
message TGeneralFeatureStorage {  
    string Id = 1 [json_name = "id"];  
    repeated TGeneralFeature Features = 2 [json_name = "features"];  
  
    option (schema) = {  
        Table: {  
            Name: "features"  
            Field: "Features"  
            Key: "Name"  
        }  
    };  
}
```

Логическая схема данных

```
message TGeneralFeature {  
    string Name = 1 [json_name = "name"];  
    google.protobuf.Value Payload = 2 [json_name = "payload"];  
}
```

Примеры ключей

/market-general/123/features/trusted_users//

Признак Маркета trusted_users для пользователя 123

/market-general/123/features// Все признаки Маркета

для пользователя с id 123

API

Create/Update

PUT + CAS:

- IfNotExist
- IfEqualTo

Read

GET:

- Точечное
- Range-based

Delete

DELETE:

- Точечное
- Range-based

Batch

POST:

Вариант комбинации операций,
опционально в одной транзакции

Точечное чтение

```
DECLARE $shard_id AS UInt32; // CityHash(root level id -> 123)
DECLARE $key_id AS String; // "/market-general/123/features/trusted_users"
SELECT ShardId, Key, ValueProto
FROM `data`
WHERE ShardId = $shard_id AND Key = $key;
```

Примеры ключей:

Доверенные пользователи

/market-general/123/features/trusted_users

Те, кто сейчас не подписан на пушки и не является "недавним" отписчиком.

Будем по этому тэгу показывать поп-ап "подпишись на наши пушки"

/market-general/123/features/crm_exp

```
{
  "name": "crm_exp",
  "payload": {
    "suffixes": [
      "lidogeneration"
    ]
  }
}
```

Range-based-чтение

```
DECLARE $shard_id AS UInt32; // CityHash(root level id -> 123)
DECLARE $range_start AS String; // "/market-general/123/features/"
DECLARE $range_end AS String; // "/market-general/123/features/~" – тильда максимальный код ascii
SELECT ShardId, Key, ValueProto
FROM `data`
WHERE ShardId = $shard_id AND Key >= $range_start AND Key < $range_end;
```

Batch-чтение

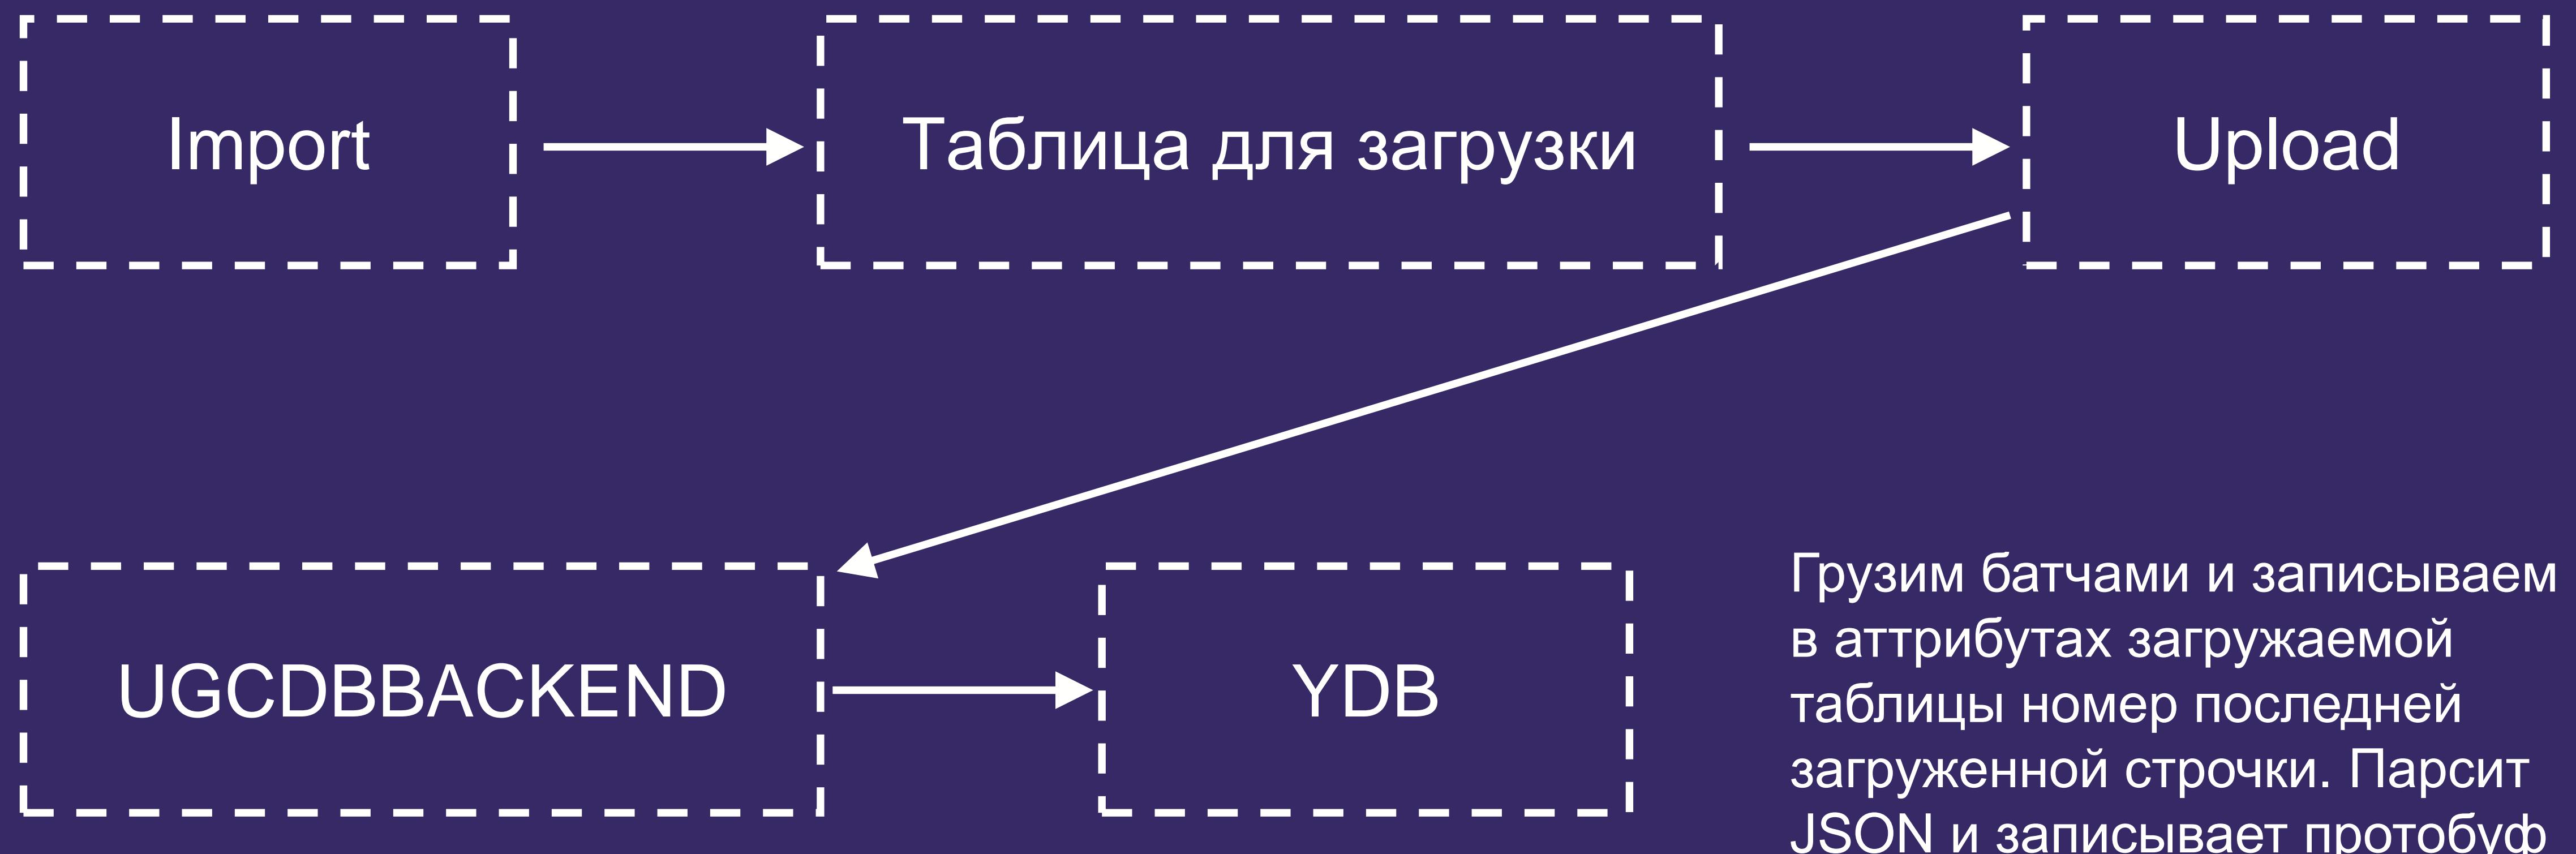
```
DECLARE $shard_id AS UInt32;
DECLARE $key_list AS List<Tuple<UInt32?,String?>>;
SELECT ShardId, Key, ValueProto
FROM `data`
WHERE (ShardId, Key) IN $key_list;
```

Модифицирующие запросы

```
// Запись
DECLARE $shard_id AS UInt32;
DECLARE $key AS String;
DECLARE $value AS String;

...
UPSERT INTO `data` (ShardId, Key, ValueProto, ...)
VALUES ($shard_id, $key, $value, ...);
// для IfNotExist и IfNotEqual используются интерактивные транзакции
// логика их обработки реализована на уровне приложения
// Удаление
DECLARE $shard_id AS UInt32;
DECLARE $key AS String;
DELETE FROM `data` WHERE ShardId = $shard_id AND Key = $key;
```

Загрузка данных



1. Что такое Feature Store?

2. Рождение Avalon

3. UGcdb Framework

4. Proxy и Data Processor

5. Технические характеристики

Avalon Proxy

Единая точка входа для чтения

Позволяет инкапсулировать
несколько различных хранилищ

API

Усечённое API для гарантии
одношардовости
пользовательских запросов

ACL

Динамическая конфигурация
доступа потребителей

Nice to have

В будущем хотелось бы работать из неё
напрямую с YDB для лучших таймингов

Avalon Data Processor

Единая точка входа для чтения

Позволяет контролировать поступающие данные

Админка

Хранит данные каталога признаков и внутренние параметры импорта оффлайн-данных

ACL

Динамическая конфигурация доступа потребителей

Nice to have

В будущем хотелось бы работать из неё напрямую с YDB для лучших таймингов

Принесли таблицу

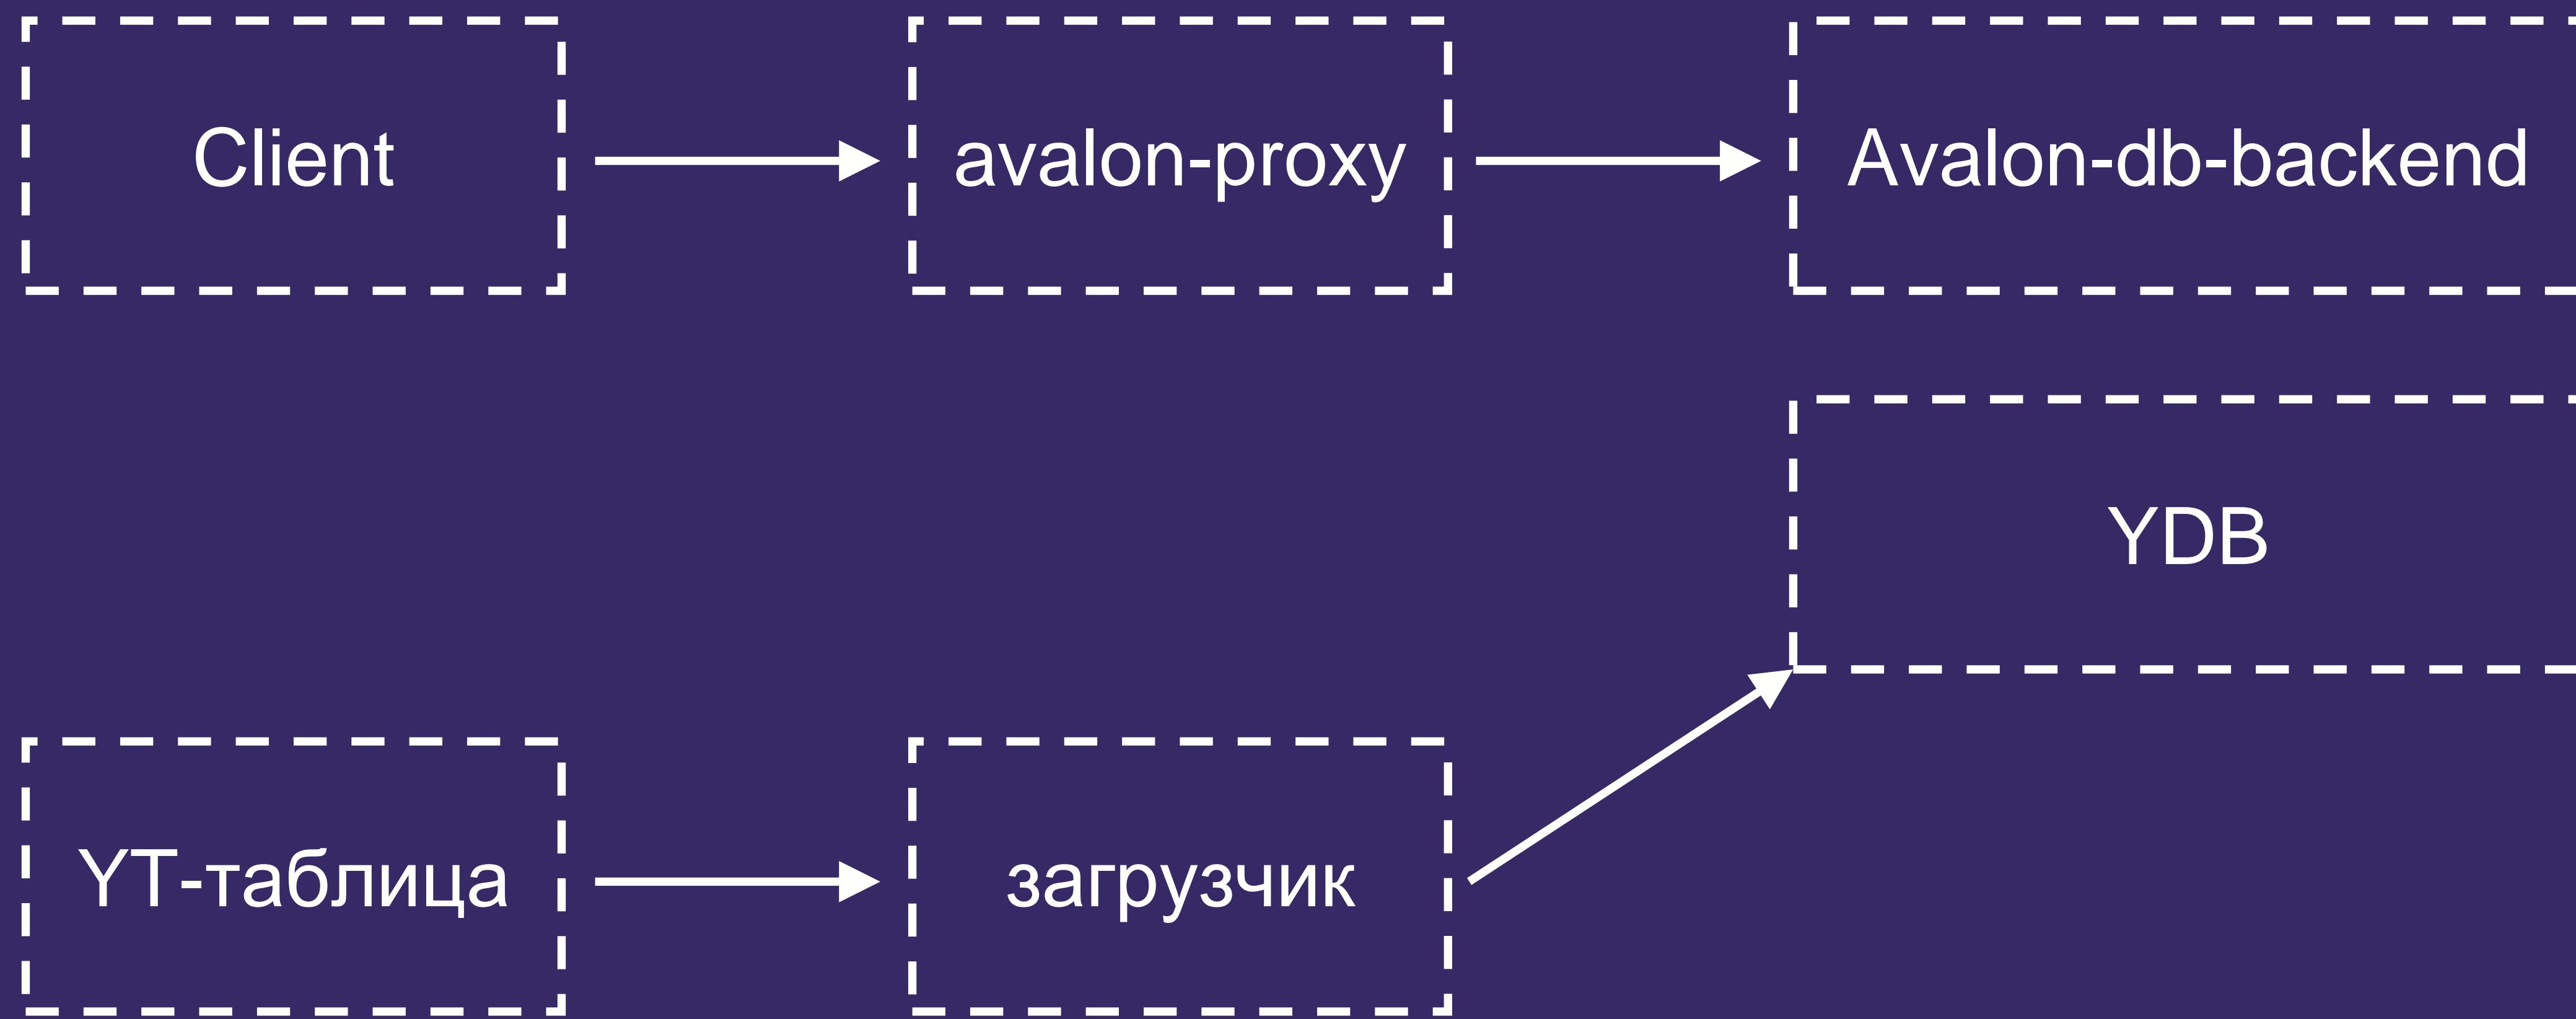
Metadata ^

Id	30c6f-86e261-3fe0191-688884f2	⌚	Rows	1 766 842 971	Table type	static	Sorted	false
Owner	robot-taxi-prd-41663		Chunks	939	Optimize for	Lookup		
Account	taxi-efficiency		Uncompressed size	73.63 GiB	Compression ratio	0.20506		
Creation time	29 May 2025 22:42:50		Compressed size	15.10 GiB	Compression codec	Iz4		
Modification time	29 May 2025 22:54:11		Primary medium	Default	Replication factor	3		
Access time	29 May 2025 22:54:12		Total disk space	45.31 GiB				
			Data weight	57.18 GiB				

« < > » # No offset Columns 2/2 ⚙ YQL Kit Jupyter DataLens Download Upload ...

#	“Data”	“Key”
0	{ “name”: “trusted_user” }	“99953137”
1	{ “name”: “trusted_user” }	“999531370”
2	{ “name”: “trusted_user” }	“999531371”

Загрузили данные и можем их получать



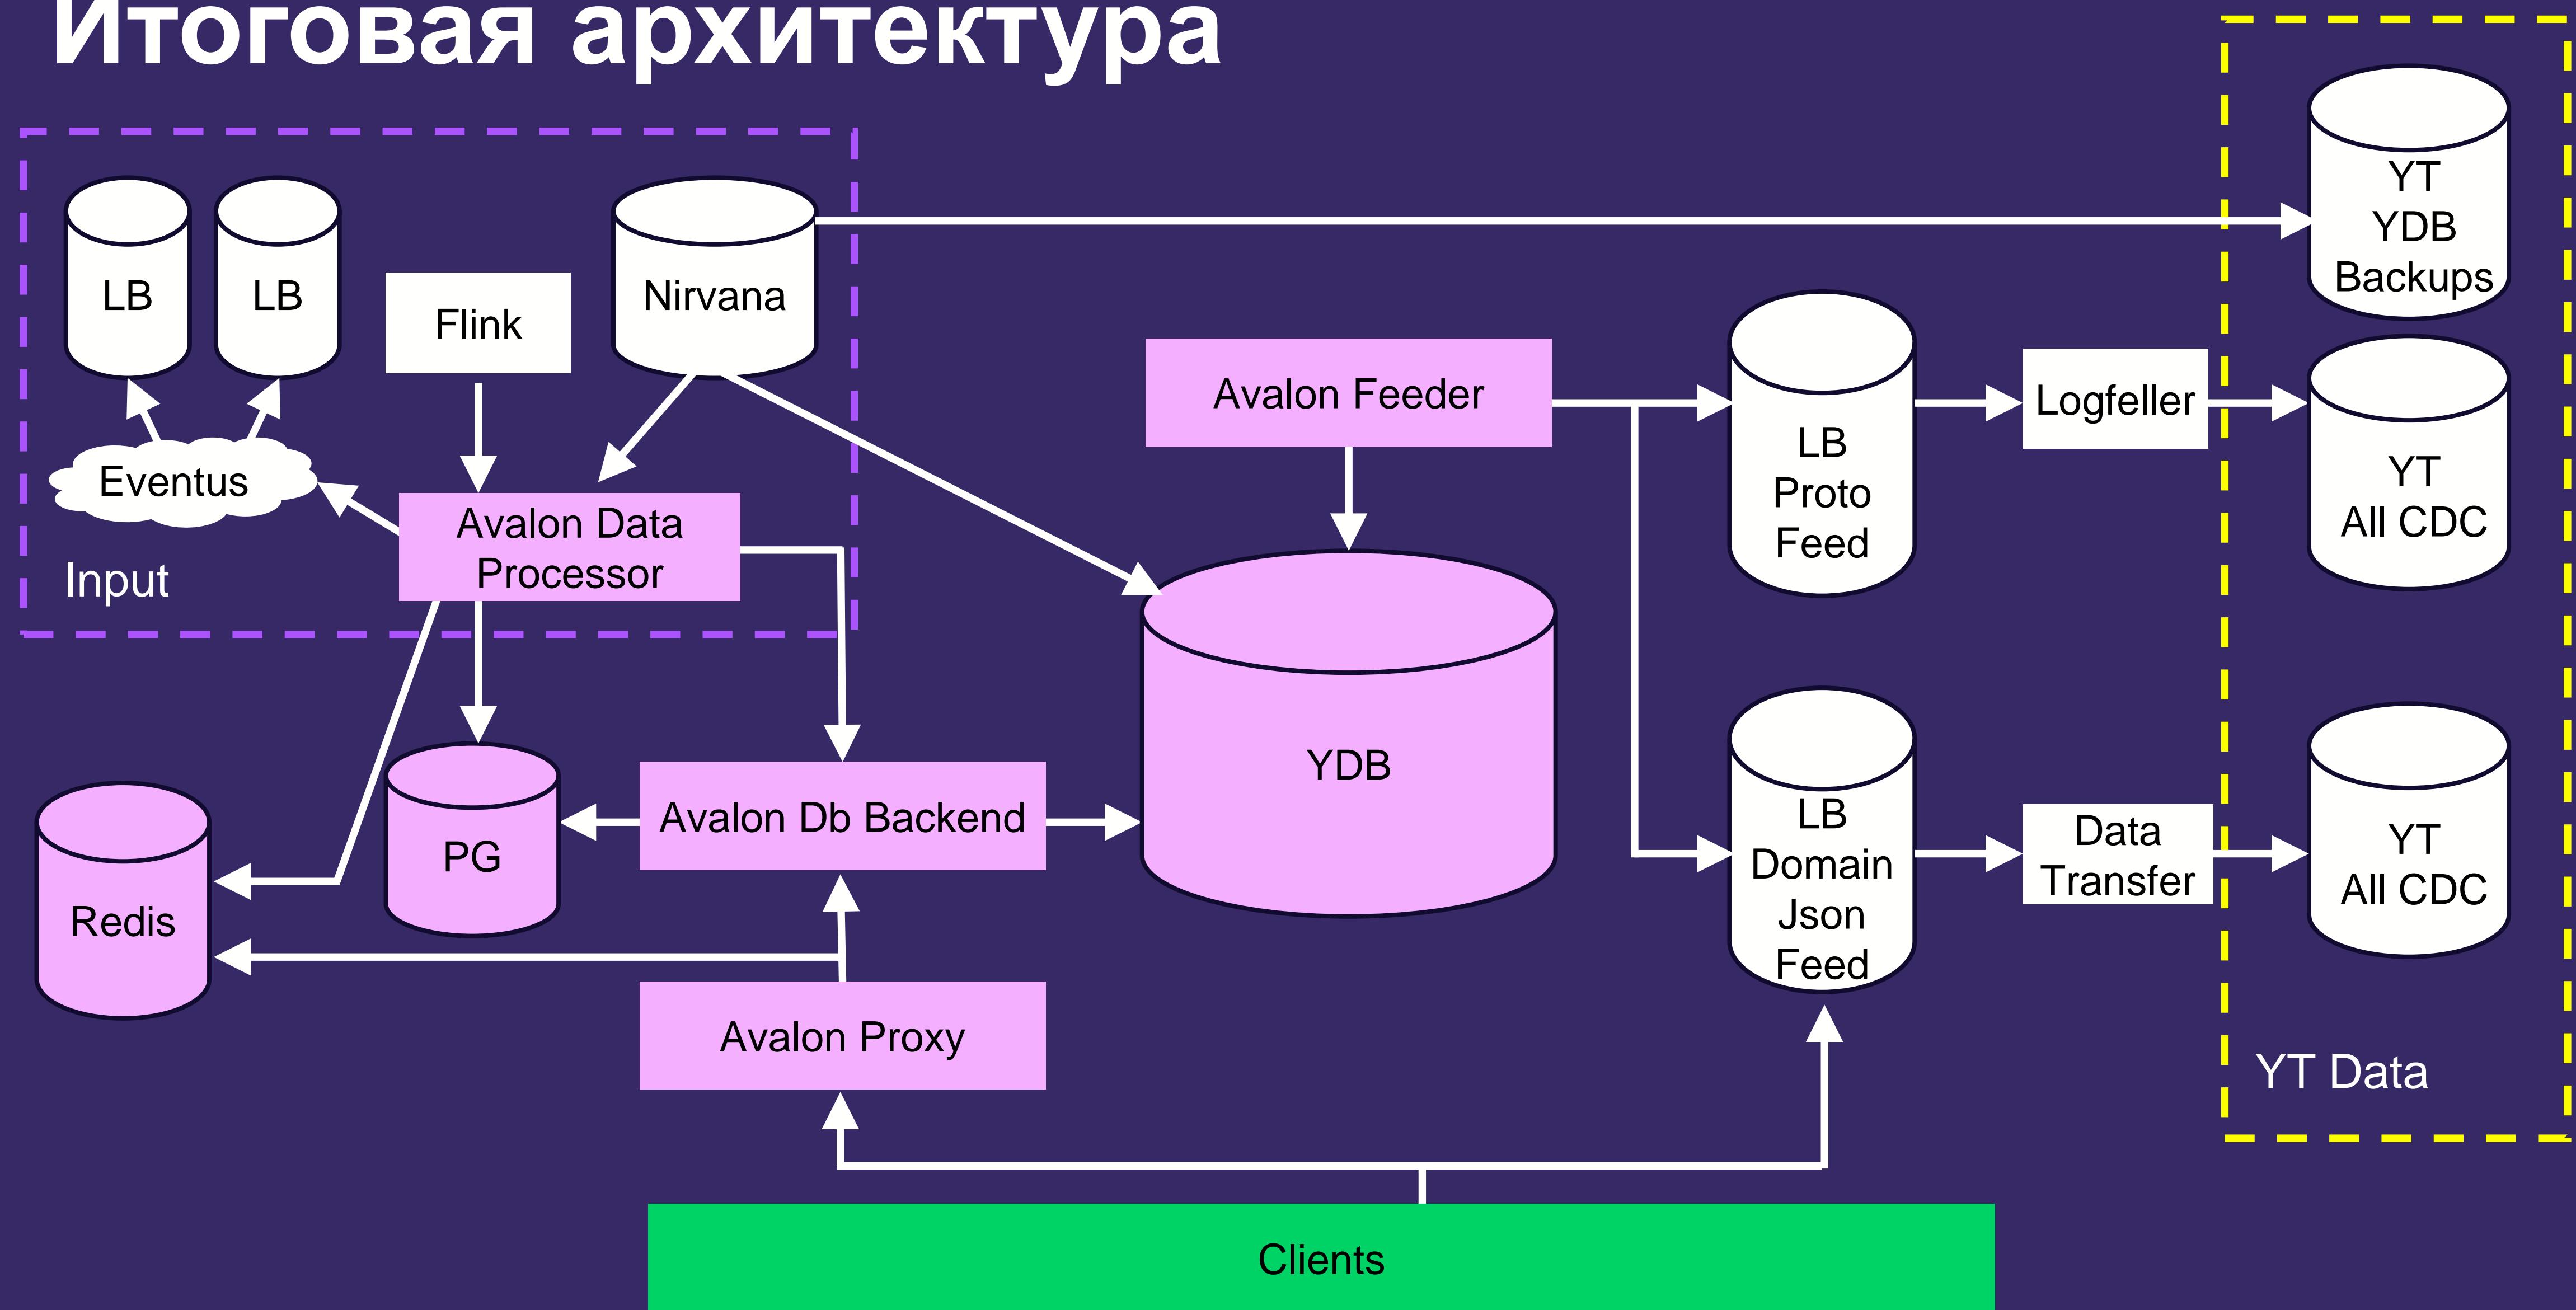
Даём доступы

```
{  
  "market-loyalty": {  
    "/market-general/{}/features": {  
      }  
    },  
  "market-perks": {  
    "/market-general/{}/features": {  
      },  
    "/passport-uids/{}/market-payment-methods": {  
      },  
    "/passport-uids/{}/market-prev-business-purchases": {  
      },  
    "/passport-uids/{}/personal-goals": {  
      }  
    },  
}
```

Счастливые пользователи

```
std::vector<std::string> AvalonProxyService::GetAvalonGeneralFeatures() const {
    auto response_opt = GetGeneralFeaturesData(avalon_get_features_task_);
    if (!response_opt) {
        return {};
    }
    auto response = response_opt.value();
    std::vector<std::string> result;
    result.reserve(response.GetFeatures().size());
    for (const auto& feature : response.GetFeatures()) {
        if (feature.GetName() == kMarketGenderPromo) {
            continue;
        }
        if (feature.HasPayload()) {
            const auto& payload = feature.GetPayload();
            if (payload.has_struct_value()) {
                const auto& protoMap = payload.struct_value().fields();
                const auto* suffixes = MapFindPtr(protoMap, "suffixes");
                if (suffixes) {
                    if (suffixes->has_list_value()) {
                        for (const auto& suffix : suffixes->list_value().values()) {
                            if (suffix.has_string_value()) {
                                result.push_back(feature.GetName() + '_' + suffix.string_value());
                                boost::to_upper(result.back()); // For compatibility with tags
                            }
                        }
                    }
                    continue;
                }
            }
            result.push_back(feature.GetName());
            boost::to_upper(result.back()); // For compatibility with tags
        }
    }
    return result;
}
```

Итоговая архитектура



Что если нам нужна история изменений?

```
message TRoot {  
    repeated TGeneralFeatureStorage DiscountsGeneral = 1 [(topic) = "discounts-general-json"];  
  
    option (schema) {  
        Table: {  
  
            Name: "discounts-general"  
            Field: "DiscountsGeneral"  
            Key: "Id"  
        }  
    }  
}
```

Что если нам нужна история изменений?

```
message TGeneralFeatureStorage {  
    string Id = 1 [json_name = "id"];  
    repeated TGeneralFeature Features = 2 [json_name = "features"];  
  
    option (schema) = {  
        Table: {  
            Name: "features"  
            Field: "Features"  
            Key: "Name"  
        }  
    };  
}
```

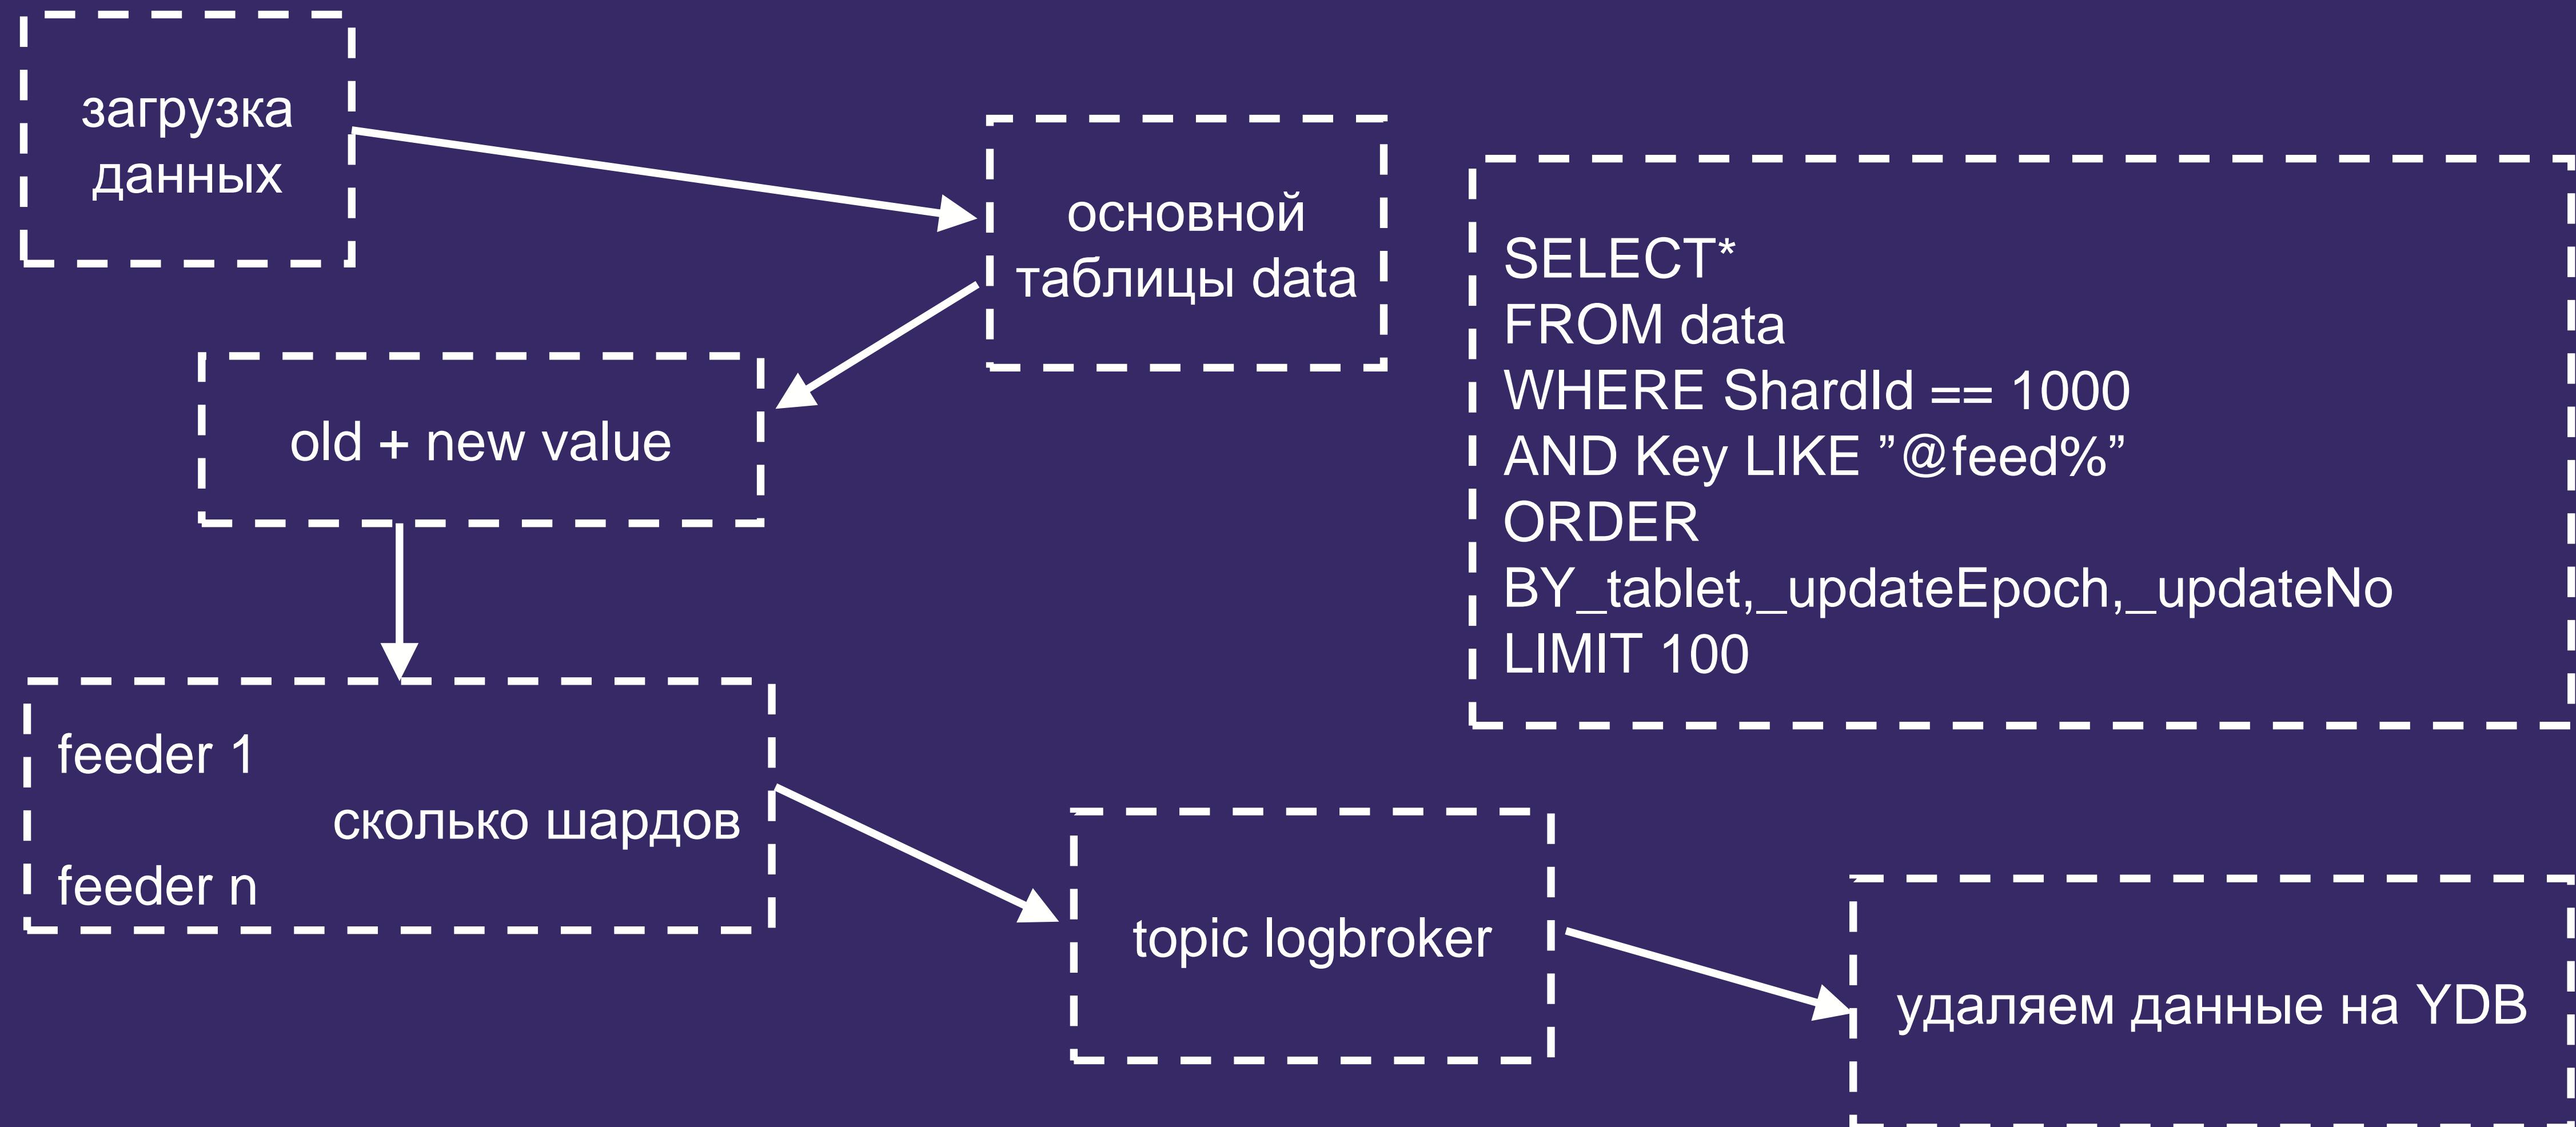
Что если нам нужна история изменений?

```
message TGeneralFeature {  
    string Name = 1 [json_name = "name"];  
    google.protobuf.Value Payload = 2 [json_name = "payload"];  
}
```

Старое и новое значение — тоже признак

```
message TFeedRecord {  
    string Key = 1;  
    TRecordMeta OldMeta = 2;  
    google.protobuf.Any OldValue = 3;  
    TRecordMeta NewMeta = 4;  
    google.protobuf.Any NewValue = 5;  
    TRequestMeta RequestMeta = 6;  
}
```

Feeder



Внешний CDC aka Feeder

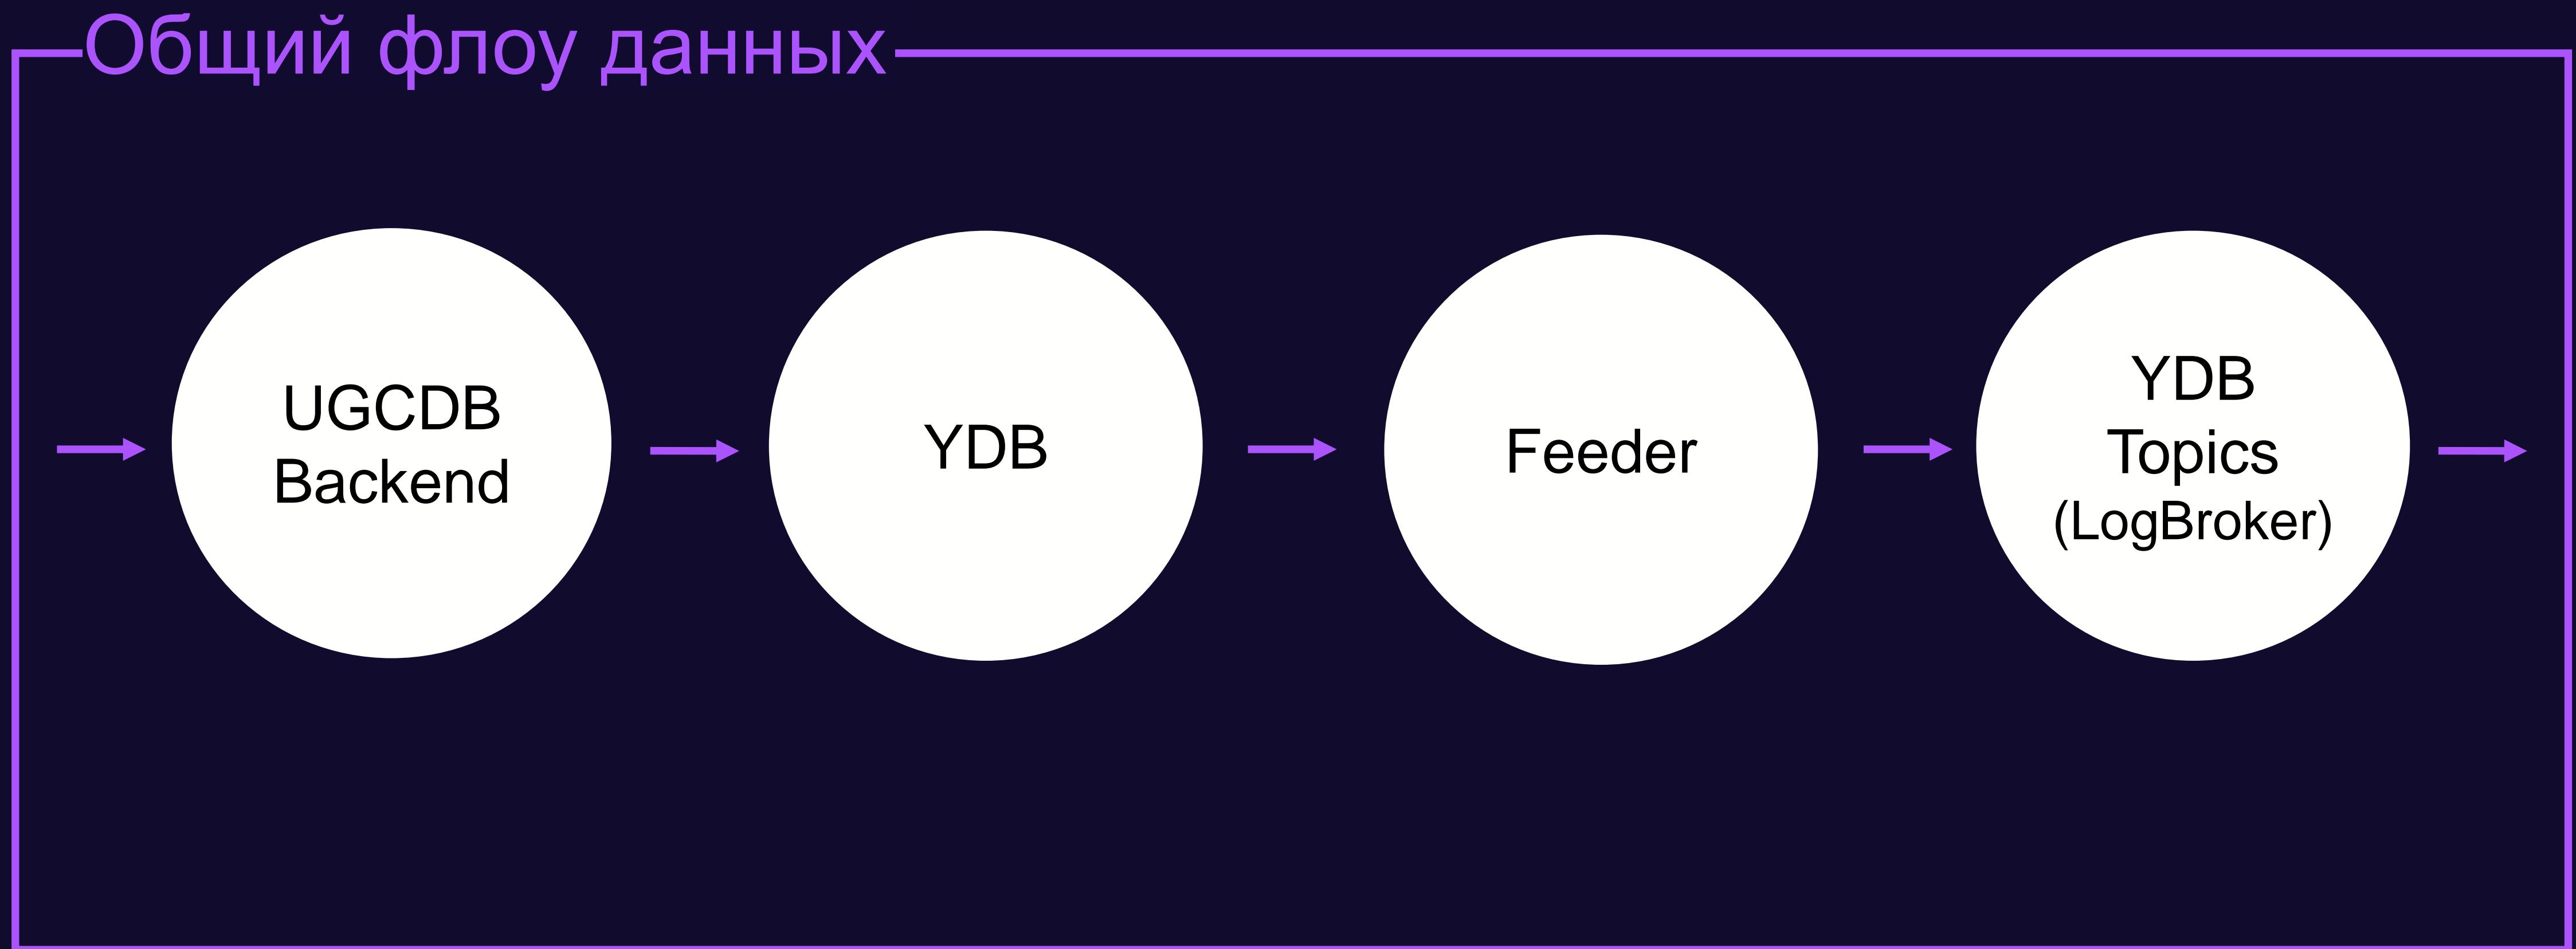
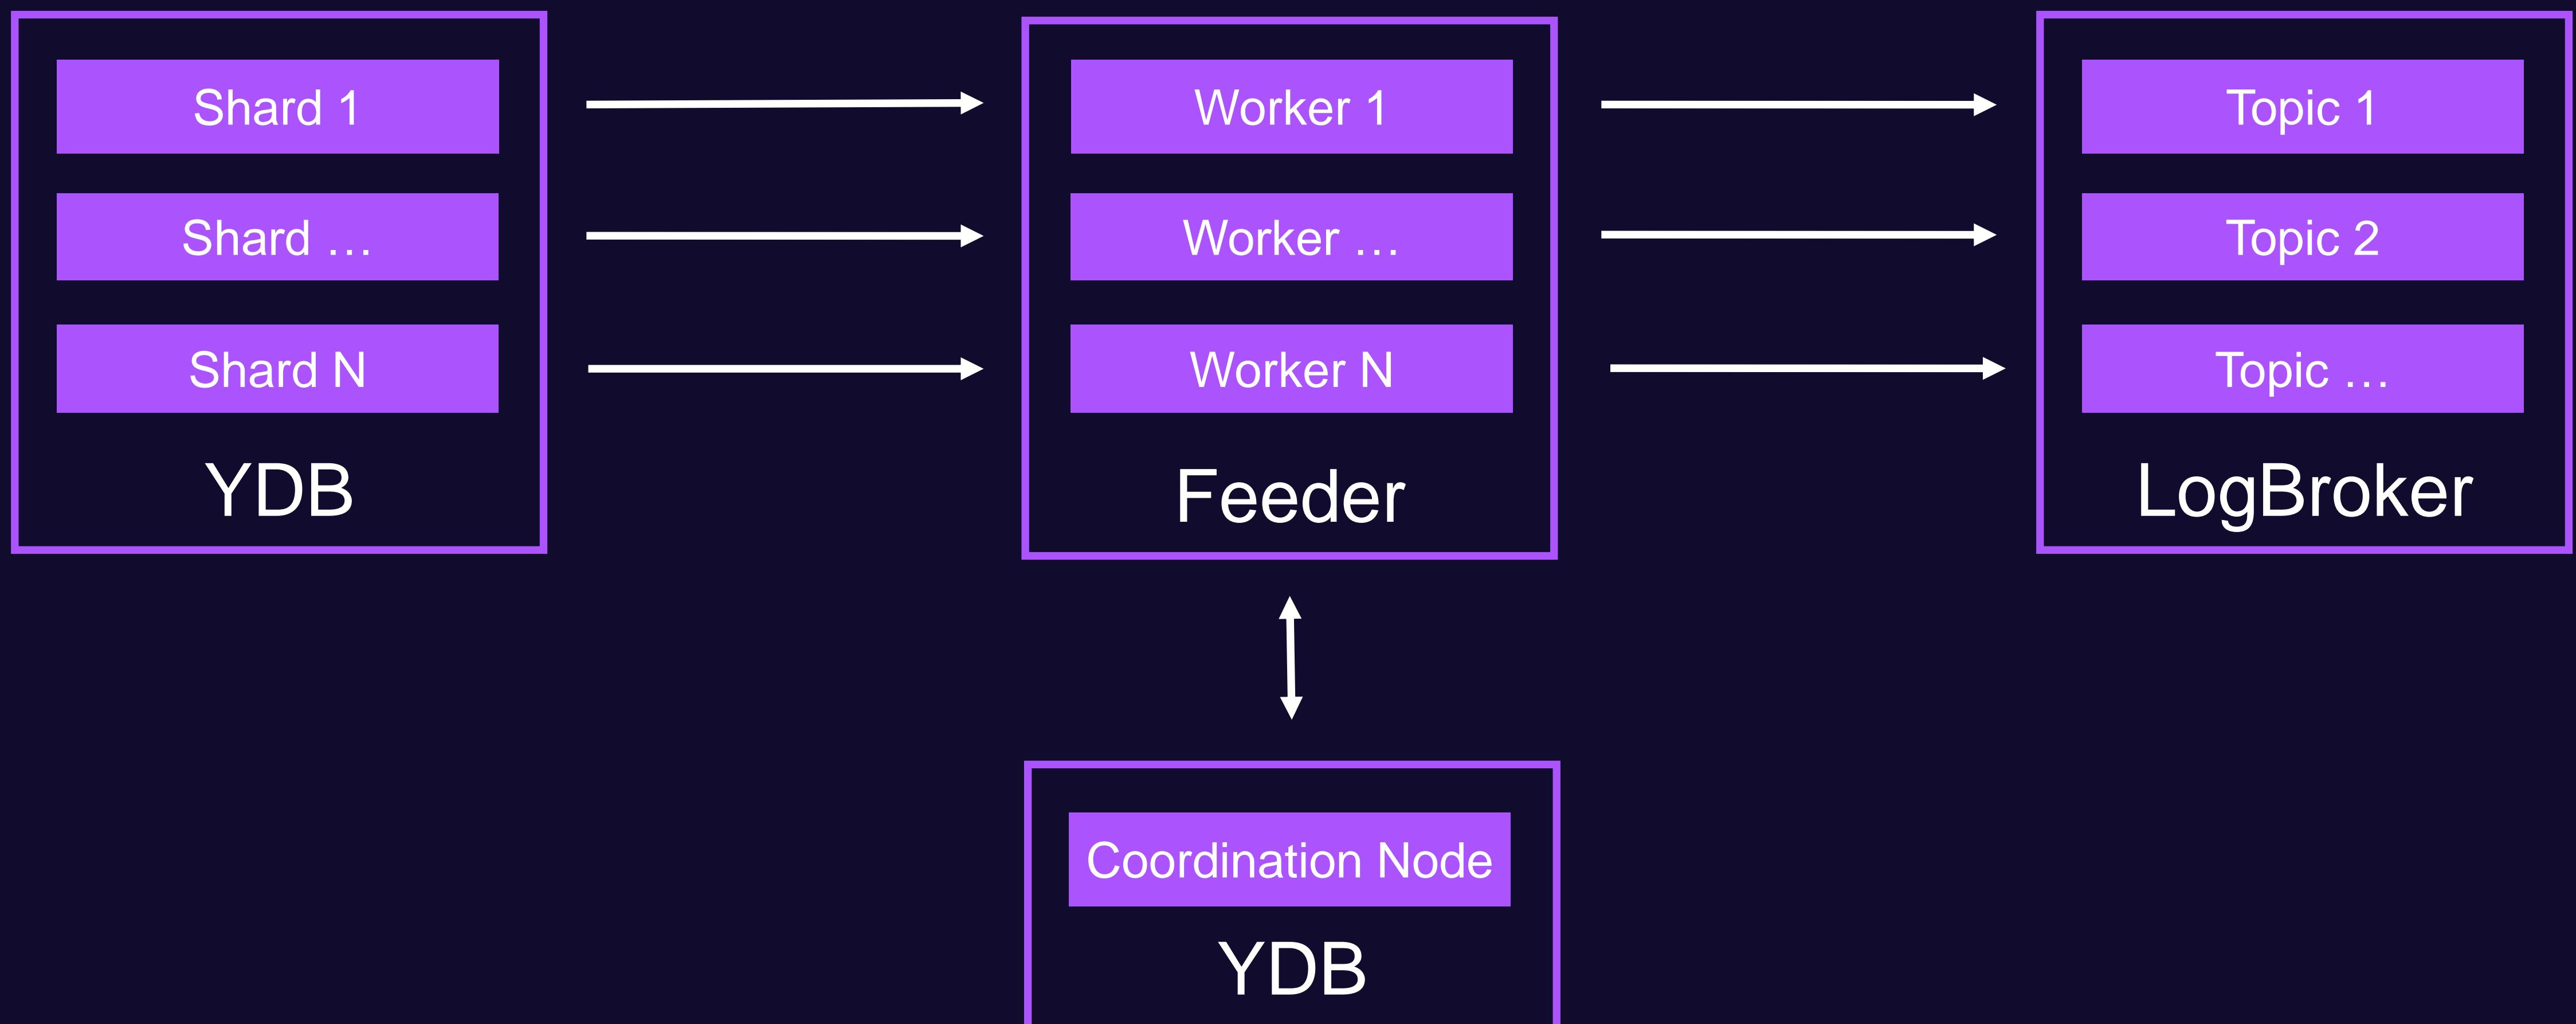
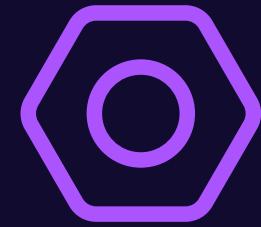


Схема устройства Feeder

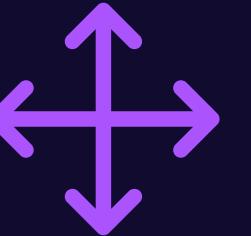


Feeder Tips&Tricks



DbBackend

- Гарантирует одновременную запись данных и диффа
- Гарантирует запись данных и диффа в один шард
- Гарантирует, что запись диффа будет иметь минимальное значение ShardId на таблетке



Feeder

- Читает только начало шарда
- Удаляет запись диффа из базы только при успешной записи в LogBroker
- Позволяет писать данные в топик как в бинарном виде, так и в JSON
- Гарантирует Exactly Once за счёт номеров обновления (updateEpoch и updateNo)



Ограничения

Данная реализация фидера не позволяет сохранить возможность шардирования по нагрузке, поэтому остаётся только шардирование по размеру шарда, при этом без обратного мержа, так как в случае мержа мы получим записи фида в середине шарда и не сможем их найти

1. Что такое Feature Store?
2. Рождение Avalon
3. UGcdb Framework
4. Proxy и Data Processor
5. Технические характеристики

Данные о нагрузке

~3 ТВ

Объём данных

~6,5 В

Количество ключей

2048

Шардов

Данные о нагрузке

100k

RPS на чтение

5ms

p95 на чтение

30k

RPS на запись,
в т.ч. RW-транзакции

**Спасибо
за внимание!**

Павел Попов
Руководитель
группы разработки
передовых технологий,
Яндекс Go

Задайте вопросы спикеру
в чате мероприятия:

